



Metodología de la Investigación Trabajo Práctico



Grupo: 5 - CCDD

Integrantes: Antolini Martín, Avecilla Tomás, Bianciotto Franco, Calcia Franco, Pace Bruno, Zorzolo
Rubio Juana.

Docentes: Lic. María Cecilia Ribeco, Ing. Pérez Matias Agustín.

1. Introducción

El transporte público constituye uno de los pilares fundamentales de la movilidad urbana en las grandes ciudades. En el caso de Buenos Aires, la red de subterráneos representa un sistema crítico que moviliza diariamente a millones de personas, conectando distintos puntos estratégicos de la ciudad y contribuyendo de manera significativa a la reducción de la congestión vehicular y las emisiones de carbono. Comprender el comportamiento de la demanda en este sistema no es solo un ejercicio académico, sino una necesidad concreta para la planificación eficiente del servicio, la asignación de recursos y la toma de decisiones de política pública.

En este contexto, la Ciencia de Datos y el aprendizaje automático (Machine Learning) ofrecen herramientas poderosas para extraer conocimiento a partir de grandes volúmenes de información. A través del análisis de registros históricos de pasajeros por estación y molinete, la evolución de tarifas y las variables temporales asociadas, es posible identificar patrones de comportamiento, detectar anomalías y construir modelos capaces de anticipar la demanda futura con un nivel de precisión significativo.

El presente trabajo final integrador tiene como propósito aplicar la metodología de la investigación científica al desarrollo de un proyecto integral de Ciencia de Datos sobre la red de subtes de la Ciudad Autónoma de Buenos Aires. A partir de un dataset que incluye información sobre estaciones, flujo de pasajeros, tarifas y datos temporales, se llevará a cabo un proceso completo que abarca desde la exploración y limpieza de los datos hasta la construcción y evaluación de modelos predictivos supervisados y no supervisados.

A pesar de la relevancia del subte en la movilidad urbana, en los últimos años se ha observado una caída significativa en la cantidad de pasajeros, cuya explicación no resulta unívoca. Factores como cambios en los hábitos laborales, variaciones tarifarias y condiciones del servicio podrían estar influyendo de manera simultánea. En este contexto, surge la necesidad de analizar cuantitativamente cuáles son los determinantes principales de dicha caída.

1.1 Objetivos

1.1.2 Objetivo general

Desarrollar un modelo predictivo que permita estimar la demanda de pasajeros en la red de subtes de Buenos Aires, aplicando técnicas de Machine Learning y siguiendo un enfoque metodológico riguroso orientado a la validación de hipótesis.

1.1.3 Objetivos específicos

Realizar un análisis exploratorio de los datos (EDA) para identificar patrones de uso, estacionalidad y correlaciones entre variables.

Pre-procesar y transformar el dataset para garantizar su calidad y adecuación al modelado.

Construir y comparar **modelos de regresión, clasificación y clustering aplicados al flujo de pasajeros**.

Evaluar el impacto de las **variaciones tarifarias sobre la demanda, mediante técnicas de regresión**.

Contrastar los resultados obtenidos con las hipótesis formuladas y derivar recomendaciones orientadas a la gestión del sistema de transporte.

Relevancia del análisis predictivo en sistemas de transporte urbano

La capacidad de anticipar la demanda en sistemas de transporte masivo tiene implicancias directas en la eficiencia operativa y en la experiencia de los usuarios. Una predicción precisa del flujo de pasajeros permite optimizar la frecuencia de los servicios, planificar el mantenimiento de la infraestructura y diseñar políticas tarifarias más equitativas. En ciudades como Buenos Aires, donde la red de subtes opera bajo una demanda heterogénea y fuertemente influenciada por factores socioeconómicos, laborales y temporales, el uso de modelos basados en datos históricos resulta especialmente valioso.

Asimismo, este tipo de proyectos ilustra con claridad el potencial de la Ciencia de Datos aplicada a problemas reales del sector público, en línea con la creciente adopción de enfoques de gobierno basado en evidencia y ciudades inteligentes (smart cities).

1.2 Hipótesis: Elasticidad tarifaria y caída estructural de la demanda

1.2.1 Formulación

H5: Los aumentos sostenidos en la tarifa del subte, especialmente a partir de 2024, podrían constituir uno de los principales factores explicativos de la caída en la demanda de pasajeros —por encima de variables estructurales como el teletrabajo— y su efecto varía significativamente entre líneas, siendo la Línea D la más sensible al precio y las Líneas A y E las menos elásticas.*

1.2.2 Fundamentación

Una crisis de demanda sin precedentes regionales

El subte de Buenos Aires transportó en abril de 2025 un 39% menos de pasajeros que en abril de 2019 (Chequeado, 2025). En el primer cuatrimestre de 2025, la caída acumulada alcanzó el 44,1% respecto al mismo período pre-pandemia (Infobae, 2025). Mientras que los metros de la región operan en promedio al 80% de su volumen de 2019, Buenos Aires presenta el peor desempeño relativo del continente (Skiadaressis Chequeado, 2025).

El economista Skiadaressis descompone la caída en dos componentes: aproximadamente un 20% atribuible a cambios estructurales post-pandemia (teletrabajo, nuevos hábitos de movilidad), y otro

20% vinculado directamente a la suba tarifaria, la mayor evasión y el menor costo relativo del colectivo.

El desfasaje tarifario como factor expulsivo

Desde mayo de 2024, el costo del subte duplica al del colectivo: \$963 frente a \$472 en junio de 2025 (Chequeado, 2025). El boleto acumuló un aumento nominal del 670% entre abril de 2024 y mayo de 2025 (Infobae, 2025). El Centro de Estudios Metropolitanos (CEM) califica esta situación como una "política tarifaria expulsiva" que rompió la paridad histórica entre ambos modos de transporte (Observatorio del Derecho a la Ciudad, 2025). A modo de antecedente, en 2012 un aumento similar redujo la demanda un 24% interanual.

Elasticidad-precio: evidencia diferenciada por línea

La tesis de la UDT (2020), que analizó la demanda del período 1993-2016, estimó una elasticidad-precio inelástica (entre -0,1 y -0,2): una suba del 10% en la tarifa reduce la demanda entre 1% y 2%. Sin embargo, se hallaron diferencias significativas por línea: la Línea D es la más sensible al precio, mientras que las Líneas A y E son las menos elásticas. Informes del CEM (2025) confirman que las líneas B y D son las que mayor pérdida de pasajeros registran en el período reciente, agravada por problemas de infraestructura y servicio.

Cambios en patrones temporales

Informes del Gobierno de la Ciudad sobre movilidad post-COVID muestran que las matrices origen-destino se modificaron: el pico de las 9:00 AM se diluyó por efecto del trabajo híbrido. Las líneas D y E, que sirven zonas de oficinas, muestran una recuperación más lenta que las líneas C y H, que conectan con la red ferroviaria metropolitana (Observatorio del Derecho a la Ciudad, 2025).

Comparación internacional

Ciudades como Helsinki recuperaron el 90% de sus pasajeros de metro pese al teletrabajo; Madrid superó los niveles de 2019 tras reducir 50% el costo del pasaje (Observatorio del Derecho a la Ciudad, 2025). Esto refuerza que la política tarifaria es un instrumento determinante en la recuperación de la demanda.

Abordaje metodológico

Para validar esta hipótesis se propone: (1) estimar la elasticidad-precio mediante regresión lineal múltiple, controlando por variables temporales y calidad de servicio; (2) construir modelos segmentados por línea para verificar diferencias en la sensibilidad al precio; (3) aplicar análisis de series temporales (ARIMA/SARIMA) con la tarifa como variable exógena; y (4) realizar tests de cambio estructural (Chow o Bai-Perron) para evaluar si la ruptura tarifaria de mayo 2024 constituye un punto de quiebre significativo. Las métricas de evaluación incluirán R^2 ajustado, MAE, RMSE y coeficientes de elasticidad con intervalos de confianza al 95%.

2. Marco Teórico

2.1. Metodología de la investigación en Ciencia de Datos

El desarrollo de proyectos de Ciencia de Datos en contextos aplicados, como el análisis de sistemas de transporte urbano, requiere la adopción de un enfoque metodológico estructurado que permita garantizar la validez y reproducibilidad de los resultados. En este sentido, se emplea un diseño cuantitativo de tipo predictivo, basado en el análisis de datos históricos y en la construcción de modelos capaces de identificar patrones y generalizar comportamientos observados en la demanda de pasajeros del sistema de subtes.

El proceso metodológico se organiza en etapas sucesivas que incluyen la comprensión del problema, la exploración de los datos, su preparación, el modelado y la evaluación de resultados.

En este marco, el trabajo se basa en el análisis de datos observacionales, donde la formulación de hipótesis cumple un rol central al guiar el proceso de modelado. El objetivo no se limita a identificar patrones en los datos, sino que busca estimar relaciones entre variables y evaluar su impacto. En particular, se analiza la relación entre la tarifa del servicio y la demanda de pasajeros, integrando herramientas de estadística inferencial con técnicas de aprendizaje automático para su validación empírica.

2.2. Fundamentos de Machine Learning aplicado al transporte urbano

El Machine Learning constituye una rama de la inteligencia artificial que permite desarrollar modelos capaces de aprender patrones a partir de datos sin necesidad de ser programados explícitamente para cada tarea. Dentro de este campo, se distinguen principalmente dos enfoques:

Aprendizaje supervisado, donde el modelo se entrena con datos etiquetados. Se aplica principalmente a problemas de regresión (predicción de valores continuos, como el número de pasajeros) y clasificación (asignación de categorías, como niveles de demanda).

Aprendizaje no supervisado, donde el objetivo es descubrir estructuras ocultas en los datos sin etiquetas previas. Técnicas como el clustering permiten identificar agrupamientos naturales entre observaciones.

Modelos utilizados

Regresión lineal múltiple: técnica de aprendizaje supervisado que modela la relación entre una variable dependiente continua y múltiples variables independientes, asumiendo una relación lineal. Su ventaja principal radica en la interpretabilidad de los coeficientes, que representan el efecto marginal de cada variable predictora sobre la variable respuesta. La ecuación general toma la forma $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \epsilon$, donde β_i son los coeficientes estimados y ϵ es el término de error.

ARIMA/SARIMA (Autoregressive Integrated Moving Average / Seasonal ARIMA): modelos de series temporales que capturan la estructura de autocorrelación y estacionalidad en datos secuenciales. ARIMA se parametriza mediante tres componentes (p, d, q): el orden autorregresivo, el grado de diferenciación y el orden de media móvil. **SARIMA extiende este enfoque incorporando componentes estacionales (P, D, Q, s)**, lo que resulta especialmente útil para datos con patrones periódicos recurrentes.

Métricas de evaluación

R² ajustado (coeficiente de determinación ajustado): mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo, penalizando la inclusión de variables que no aportan poder explicativo. Un valor cercano a 1 indica un ajuste elevado, mientras que valores bajos sugieren que el modelo no captura adecuadamente la relación entre las variables.

MAE (Mean Absolute Error – Error Absoluto Medio): calcula el promedio de las diferencias absolutas entre los valores predichos y los observados. Ofrece una medida directa e interpretable del error promedio del modelo en las mismas unidades que la variable objetivo.

RMSE (Root Mean Squared Error – Raíz del Error Cuadrático Medio): similar al MAE, pero penaliza con mayor intensidad los errores grandes al elevar al cuadrado las diferencias antes de promediarlas. Resulta útil para detectar modelos con predicciones atípicas significativas.

Parámetros relevantes

En los modelos de regresión, los coeficientes de elasticidad con intervalos de confianza al 95% permiten cuantificar la sensibilidad de la variable dependiente ante cambios en las variables predictoras, con un nivel de certeza estadísticamente significativo. En los modelos ARIMA/SARIMA, la selección de los parámetros (p , d , q) y sus componentes estacionales se realiza mediante criterios de información como AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion), que buscan el equilibrio entre ajuste y parsimonia del modelo.

2.3 Elasticidad de la demanda en transporte

Desde la teoría económica, la elasticidad-precio de la demanda mide la sensibilidad de la cantidad demandada ante cambios en el precio. Se define formalmente como el cociente entre la variación porcentual de la cantidad demandada y la variación porcentual del precio. Cuando el valor absoluto de la elasticidad es menor a 1, la demanda se considera inelástica; cuando es mayor a 1, elástica.

En sistemas de transporte público, esta relación suele ser inelástica en el corto plazo, dado que los usuarios dependen del servicio para sus desplazamientos cotidianos y las alternativas de movilidad no son inmediatamente sustituibles. Sin embargo, la elasticidad puede variar según factores como la disponibilidad de modos de transporte alternativos, el nivel de ingresos de la población, las características del servicio (frecuencia, cobertura, comodidad) y el horizonte temporal del análisis.

La literatura sobre economía del transporte señala que, en el largo plazo, incrementos sostenidos en las tarifas pueden provocar desplazamientos modales —es decir, la migración de los usuarios hacia otros medios de transporte— especialmente cuando la brecha de precios entre modos alternativos se amplía significativamente. Este fenómeno puede analizarse mediante modelos de regresión que estimen el efecto marginal del precio sobre la cantidad de pasajeros, controlando por variables temporales y espaciales.

3. Metodología

3.1 Diseño metodológico

El presente trabajo adopta un enfoque **cuantitativo, explicativo y predictivo**, orientado al análisis de datos históricos del sistema de subtes de Buenos Aires. El objetivo no solo es describir el comportamiento de la demanda, sino también construir modelos capaces de anticiparla y evaluar relaciones causales entre variables.

El diseño es de tipo **no experimental**, dado que los datos observados no son manipulados, sino analizados en su contexto real.

Aplicación del marco teórico al problema de estudio

Los fundamentos descritos en el marco teórico se aplican de manera directa al análisis de la red de subtes de Buenos Aires. La metodología de investigación en Ciencia de Datos (sección 2.1) estructura el proceso completo de trabajo: desde la formulación de la hipótesis sobre la elasticidad tarifaria hasta la validación cuantitativa mediante modelos predictivos. Los fundamentos de Machine Learning (sección 2.2) proveen las herramientas técnicas para construir los modelos de regresión lineal múltiple y series temporales ARIMA/SARIMA que se utilizarán para estimar la demanda y cuantificar el impacto de la tarifa. Finalmente, el concepto de elasticidad-precio de la demanda (sección 2.3) constituye el eje analítico central de la hipótesis: se busca determinar si los aumentos tarifarios recientes han tenido un efecto significativo en la reducción de pasajeros.

A partir de la evidencia disponible, el subte de Buenos Aires transportó en abril de 2025 un 39% menos de pasajeros que en abril de 2019 (Chequeado, 2025), con una caída acumulada del 44,1% en el primer cuatrimestre de 2025 respecto al período pre-pandemia (Infobae, 2025). El economista Skiadaressis descompone esta caída en dos componentes: un 20% atribuible a cambios estructurales post-pandemia y otro 20% vinculado a la suba tarifaria (Chequeado, 2025). Desde mayo de 2024, el costo del subte duplica al del colectivo —\$963 frente a \$472 en junio de 2025—, acumulando un aumento nominal del 670% entre abril de 2024 y mayo de 2025 (Infobae, 2025). El CEM califica esta situación como una "política tarifaria expulsiva" (Observatorio del Derecho a la Ciudad, 2025).

La tesis de la UTDT (2020) estimó una elasticidad-precio inelástica (entre -0,1 y -0,2), con diferencias significativas por línea: la Línea D es la más sensible al precio y las Líneas A y E las menos elásticas. Informes del CEM (2025) confirman que las líneas B y D registran la mayor pérdida de pasajeros en el período reciente. A nivel internacional, ciudades como Helsinki y Madrid lograron recuperar o superar sus niveles pre-pandemia mediante políticas tarifarias favorables (Observatorio del Derecho a la Ciudad, 2025), lo que refuerza la relevancia del factor precio como determinante de la demanda.

3.2. Herramientas

Para el desarrollo del presente proyecto se utilizará un conjunto de herramientas de software de código abierto, ampliamente adoptadas en la comunidad de Ciencia de Datos:

- Python: lenguaje de programación principal del proyecto, seleccionado por su amplio ecosistema de librerías orientadas al análisis de datos, el aprendizaje automático y la visualización.

- **Pandas:** librería para la manipulación y el análisis de datos tabulares. Se utilizará para la carga, limpieza, transformación y exploración del dataset de pasajeros, tarifas y estaciones.
- **NumPy:** librería de cómputo numérico que provee estructuras de datos eficientes (arrays) y funciones matemáticas utilizadas como base por las demás herramientas del ecosistema.
- **Matplotlib y Seaborn:** librerías de visualización de datos. Matplotlib ofrece un control granular sobre los gráficos, mientras que Seaborn facilita la creación de visualizaciones estadísticas con una sintaxis más concisa. Se emplearán para el análisis exploratorio (EDA) y la presentación de resultados.
- **Scikit-learn:** librería de aprendizaje automático que provee implementaciones de modelos de regresión, clasificación y clustering, así como herramientas para la evaluación de modelos (métricas como MAE, RMSE, R^2), la validación cruzada y el preprocesamiento de datos.
- **Statsmodels:** librería orientada a la modelización estadística y econométrica. Se utilizará para la construcción de modelos de series temporales (ARIMA/SARIMA), la regresión lineal con análisis de significancia estadística y los tests de cambio estructural.
- **Jupyter Notebook:** entorno de desarrollo interactivo que permite combinar código, visualizaciones y texto narrativo en un mismo documento. Facilita la documentación reproducible del proceso de análisis y modelado.

3.3. Detalle de las etapas

3.3.1 Etapa 1 – Exploración visual de los datos (EDA)

En esta etapa se realizará un análisis descriptivo inicial del dataset, con el objetivo de comprender su estructura y detectar patrones relevantes. Se utilizarán técnicas de visualización y estadística descriptiva para:

- Analizar la evolución temporal del flujo de pasajeros.
- Identificar estacionalidades (diarias, semanales, mensuales).
- Explorar diferencias entre líneas y estaciones.
- Evaluar correlaciones entre variables (por ejemplo, tarifa vs pasajeros).
- Este análisis permitirá generar primeras intuiciones sobre la hipótesis planteada.

3.3.2 Etapa 2 – Limpieza y transformación

Se procederá a preparar los datos para su uso en modelos de Machine Learning, mediante:

- Tratamiento de valores faltantes (imputación o eliminación).
- Detección y manejo de outliers.
- Detección y manejo de duplicados.
- Transformación de variables (por ejemplo, fechas a variables temporales como día de semana).
- Normalización o estandarización de variables numéricas.
- Además, se generarán nuevas variables derivadas, como indicadores de tarifa, períodos pre y post aumentos, o agrupaciones por franjas horarias.

3.3.3 Etapa 3 – Modelado con Machine Learning

Se implementará el siguiente enfoque de modelado, conectando las técnicas descritas en el marco teórico (sección 2.2) con el problema de estudio:

- **Regresión lineal múltiple:** se aplicará para predecir la cantidad de pasajeros y analizar el impacto de la tarifa sobre la demanda. Los coeficientes obtenidos permitirán estimar la

elasticidad-precio descrita en la sección 2.3, controlando por variables temporales y espaciales.

- ARIMA/SARIMA: se aplicarán modelos de series temporales con la tarifa como variable exógena para capturar los patrones estacionales de la demanda y proyectar su evolución.
- El modelo será evaluado mediante las métricas definidas en el marco teórico: MAE, RMSE y R^2 ajustado.

3.4. Validación de la hipótesis

Finalmente, se analizarán los resultados obtenidos para evaluar la hipótesis planteada:

- Se medirá el impacto de la tarifa sobre la demanda mediante coeficientes de regresión.
- Se analizarán diferencias entre líneas para identificar elasticidades distintas.
- Se realizarán tests de cambio estructural (Chow o Bai-Perron) para evaluar si la ruptura tarifaria de mayo de 2024 constituye un punto de quiebre significativo en la serie de demanda.



Bibliografía

1. Chequeado. (2025). [Aumentó el subte en CABA: ¿qué promociones ofrecen los bancos y billeteras virtuales para pagar menos el boleto?](#)
2. Chequeado. (2025). [Cada vez menos gente viaja en el subte porteño: la cantidad de pasajeros cayó un 39% desde 2019.](#)
3. Centro de Estudios Metropolitanos. (2025). [Cada vez menos gente viaja en subte.](#)
4. Infobae. (2025). [Se desplomó 40% el uso del subte desde la pandemia: el impacto del teletrabajo y la suba del boleto.](#)
5. Observatorio del Derecho a la Ciudad. (2025). [Informe sobre la evolución de pasajeros y la tarifa del subte de Buenos Aires \(2015–2025\).](#)

