



Metodología de la Investigación Trabajo Práctico



Grupo: 5 - CCDD

Integrantes: Antolini Martín, Avecilla Tomás, Bianciotto Franco, Calcia Franco, Pace Bruno, Zorzolo
Rubio Juana.

Docentes: Lic. María Cecilia Ribecco, Ing. Pérez Matias Agustín.

JUNIO 2026

Resumen

El presente Trabajo Final Integrador analiza los factores asociados a la caída de la demanda de pasajeros en la red de subterráneos de la Ciudad Autónoma de Buenos Aires. El estudio se centra en evaluar el impacto de las variaciones tarifarias registradas en los últimos años y compararlo con la influencia de otros factores estructurales y eventos extraordinarios, en particular la pandemia de COVID-19. Para ello, se adoptó un enfoque cuantitativo de carácter explicativo y predictivo, basado en el análisis de datos históricos de flujo de pasajeros y cuadros tarifarios correspondientes al período 2014-2025.

Con el fin de abordar esta problemática, se aplicaron distintas técnicas de análisis de datos y modelado estadístico orientadas a estudiar la relación entre la demanda y el precio, analizar la evolución temporal de los pasajeros, segmentar perfiles de utilización de las estaciones e identificar posibles cambios estructurales en la serie. Los resultados obtenidos muestran una relación inversa y moderada entre la tarifa real y la cantidad de pasajeros transportados, lo que indica que la demanda responde a las variaciones de precio de manera inelástica. Sin embargo, la evidencia sugiere que los incrementos tarifarios no explican por sí solos la caída sostenida de la demanda ni constituyen un punto de ruptura abrupto en su evolución. En cambio, los resultados señalan que dicha contracción responde a una combinación de factores, entre los que sobresalen el impacto de la pandemia y la consolidación de nuevos hábitos de movilidad urbana.

Palabras clave: Ciencia de Datos, demanda de pasajeros, movilidad urbana, transporte público, análisis predictivo.

Índice

Resumen.....	1
Índice.....	2
Índice de imágenes.....	3
1. Introducción.....	4
1.1 Objetivos.....	5
1.1.2 Objetivo general.....	5
1.1.3 Objetivos específicos.....	5
1.2 Hipótesis: Elasticidad tarifaria y caída estructural de la demanda.....	6
1.2.1 Formulación.....	6
1.2.2 Fundamentación.....	6
Una crisis de demanda sin precedentes regionales.....	6
El desfasaje tarifario como factor expulsivo.....	6
Abordaje metodológico.....	7
2. Marco Teórico.....	8
2.1. Metodología de la investigación en Ciencia de Datos.....	8
2.2. Fundamentos de Machine Learning aplicado al transporte urbano.....	8
2.3 Elasticidad de la demanda en transporte.....	11
3. Metodología.....	12
3.1 Diseño metodológico.....	12
3.2. Herramientas.....	13
3.3. Detalle de las etapas.....	14
3.4. Validación de la hipótesis.....	16
4. Propuesta de solución.....	17
4.1. Desarrollo del modelo predictivo.....	17
4.2 Análisis comparativo de algoritmos utilizados.....	22
4.3 Recomendaciones basadas en los resultados.....	23
5. Conclusiones.....	24
5.1. Contraste entre hipótesis y resultados obtenidos.....	24
5.2. Reflexión sobre la validez del modelo predictivo en la toma de decisiones de transporte.....	28
Referencias.....	31
Anexo.....	31

Índice de imágenes

- [Figura 1. Gráfico de elasticidad según modelo de regresión lineal múltiple.](#)
- [Figura 2. Gráfico de pronóstico de viajes mensuales con modelo SARIMAX.](#)
- [Figura 3. Gráfico de elasticidad según modelo de regresión lineal múltiple.](#)
- [Figura 4. Gráfico de serie temporal del total de viajes en subte en CABA.](#)
- [Figura 5. Gráfico de elasticidad según modelo de regresión lineal múltiple.](#)



1. Introducción

El transporte público constituye uno de los pilares fundamentales de la movilidad urbana en las grandes ciudades. En el caso de Buenos Aires, la red de subterráneos representa un sistema crítico que moviliza diariamente a millones de personas, conectando distintos puntos estratégicos de la ciudad y contribuyendo de manera significativa a la reducción de la congestión vehicular y las emisiones de carbono. Comprender el comportamiento de la demanda en este sistema no es solo un ejercicio académico, sino una necesidad concreta para la planificación eficiente del servicio, la asignación de recursos y la toma de decisiones de política pública.

En este contexto, la Ciencia de Datos y el aprendizaje automático (Machine Learning) ofrecen herramientas poderosas para extraer conocimiento a partir de grandes volúmenes de información. A través del análisis de registros históricos de pasajeros por estación y molinete, la evolución de tarifas y las variables temporales asociadas, es posible identificar patrones de comportamiento, detectar anomalías y construir modelos capaces de anticipar la demanda futura con un nivel de precisión significativo.

El presente trabajo final integrador tiene como propósito aplicar la metodología de la investigación científica al desarrollo de un proyecto integral de Ciencia de Datos sobre la red de subtes de la Ciudad Autónoma de Buenos Aires. A partir de un dataset que incluye información sobre estaciones, flujo de pasajeros, tarifas y datos temporales, se llevará a cabo un proceso completo que abarca desde la exploración y limpieza de los datos hasta la construcción y evaluación de modelos predictivos supervisados y no supervisados.

A pesar de la relevancia del subte en la movilidad urbana, en los últimos años se ha observado una caída significativa en la cantidad de pasajeros, cuya explicación no resulta unívoca. Factores como cambios en los hábitos laborales, variaciones tarifarias, modificaciones en los patrones de movilidad y eventos extraordinarios como la pandemia de COVID-19 podrían estar influyendo de manera simultánea. En este contexto, surge la necesidad de analizar cuantitativamente la relación entre tarifa, tiempo y demanda, evitando atribuir la caída del sistema a un único factor explicativo.

1.1 Objetivos

1.1.2 Objetivo general

Desarrollar modelos de análisis que permitan estudiar la demanda de pasajeros en la red de subtes de Buenos Aires, aplicando técnicas de Machine Learning y siguiendo un enfoque metodológico riguroso orientado a la validación de hipótesis.

1.1.3 Objetivos específicos

Realizar un análisis exploratorio de los datos (EDA) para identificar patrones de uso, estacionalidad y correlaciones entre variables.

Pre-procesar y transformar el dataset para garantizar su calidad y adecuación al modelado.

Construir modelos de regresión lineal múltiple para estimar la elasticidad-precio de la demanda y analizar el impacto de las variaciones tarifarias sobre la cantidad de pasajeros. Implementar modelos de series temporales SARIMA/SARIMAX para capturar tendencias y patrones estacionales en la evolución de la demanda. Aplicar técnicas de clustering para identificar grupos de estaciones con comportamientos de utilización similares.

Contrastar los resultados obtenidos con las hipótesis formuladas y derivar recomendaciones orientadas a la gestión del sistema de transporte.

Relevancia del análisis predictivo en sistemas de transporte urbano

La capacidad de anticipar la demanda en sistemas de transporte masivo tiene implicancias directas en la eficiencia operativa y en la experiencia de los usuarios. Una predicción precisa del flujo de pasajeros permite optimizar la frecuencia de los servicios, planificar el mantenimiento de la infraestructura y diseñar políticas tarifarias más equitativas. En ciudades como Buenos Aires, donde la red de subtes opera bajo una demanda heterogénea y fuertemente influenciada por factores socioeconómicos, laborales y temporales, el uso de modelos basados en datos históricos resulta especialmente valioso.

Asimismo, este tipo de proyectos ilustra con claridad el potencial de la Ciencia de Datos aplicada a problemas reales del sector público, en línea con la creciente adopción de enfoques de gobierno basado en evidencia y ciudades inteligentes (smart cities).

1.2 Hipótesis: Elasticidad tarifaria y caída estructural de la demanda

1.2.1 Formulación

H5: Los aumentos sostenidos en la tarifa del subte, especialmente a partir de 2024, podrían constituir uno de los principales factores explicativos de la caída en la demanda de pasajeros —por encima de variables estructurales como el teletrabajo— y su efecto varía significativamente entre líneas, siendo la Línea D la más sensible al precio y las Líneas A y E las menos elásticas.*

1.2.2 Fundamentación

Una crisis de demanda sin precedentes regionales

El subte de Buenos Aires transportó en abril de 2025 un 39% menos de pasajeros que en abril de 2019 [1]. En el primer cuatrimestre de 2025, la caída acumulada alcanzó el 44,1% respecto al mismo período pre-pandemia [4]. Mientras que los metros de la región operan en promedio al 80% de su volumen de 2019, Buenos Aires presenta el peor desempeño relativo del continente [2].

El economista Skiadaressis descompone la caída en dos componentes: aproximadamente un 20% atribuible a cambios estructurales post-pandemia (teletrabajo, nuevos hábitos de movilidad), y otro 20% vinculado directamente a la suba tarifaria, la mayor evasión y el menor costo relativo del colectivo.

El desfasaje tarifario como factor expulsivo

Desde mayo de 2024, el costo del subte duplica al del colectivo: \$963 frente a \$472 en junio de 2025 [1]. El boleto acumuló un aumento nominal del 670% entre abril de 2024 y mayo de 2025 [4]. El Centro de Estudios Metropolitanos (CEM) califica esta situación como una "política tarifaria expulsiva" que rompió la paridad histórica entre ambos modos de transporte [3]. A modo de antecedente, en 2012 un aumento similar redujo la demanda un 24% interanual.

Elasticidad-precio: evidencia diferenciada por línea

La tesis de la UTDT (2020), que analizó la demanda del período 1993-2016, estimó una elasticidad-precio inelástica (entre -0,1 y -0,2): una suba del 10% en la tarifa reduce la demanda entre 1% y 2%. Sin embargo, se hallaron diferencias significativas por línea: la Línea D es la más sensible al precio, mientras que las Líneas A y E son las menos elásticas. Informes del CEM [3]

confirman que las líneas B y D son las que mayor pérdida de pasajeros registran en el período reciente, agravada por problemas de infraestructura y servicio.

Cambios en patrones temporales

Informes del Gobierno de la Ciudad sobre movilidad post-COVID muestran que las matrices origen-destino se modificaron: el pico de las 9:00 AM se diluyó por efecto del trabajo híbrido. Las líneas D y E, que sirven zonas de oficinas, muestran una recuperación más lenta que las líneas C y H, que conectan con la red ferroviaria metropolitana [5].

Comparación internacional

Ciudades como Helsinki recuperaron el 90% de sus pasajeros de metro pese al teletrabajo; Madrid superó los niveles de 2019 tras reducir 50% el costo del pasaje [5]. Esto refuerza que la política tarifaria es un instrumento determinante en la recuperación de la demanda.

Abordaje metodológico

Para validar esta hipótesis se propone: (1) estimar la elasticidad-precio mediante regresión lineal múltiple, controlando por variables temporales y calidad de servicio; (2) construir modelos segmentados por línea para verificar diferencias en la sensibilidad al precio; (3) aplicar análisis de series temporales (SARIMA/SARIMAX) con la tarifa como variable exógena; y (4) realizar tests de cambio estructural (Chow o Bai-Perron) para evaluar si la ruptura tarifaria de mayo 2024 constituye un punto de quiebre significativo. Las métricas de evaluación incluirán R^2 ajustado, MAE, RMSE y coeficientes de elasticidad con intervalos de confianza al 95%.

2. Marco Teórico

2.1. Metodología de la investigación en Ciencia de Datos

El desarrollo de proyectos de Ciencia de Datos en contextos aplicados, como el análisis de sistemas de transporte urbano, requiere la adopción de un enfoque metodológico estructurado que permita garantizar la validez y reproducibilidad de los resultados. En este sentido, se emplea un diseño cuantitativo de tipo predictivo, basado en el análisis de datos históricos y en la construcción de modelos capaces de identificar patrones y generalizar comportamientos observados en la demanda de pasajeros del sistema de subtes.

El proceso metodológico se organiza en etapas sucesivas que incluyen la comprensión del problema, la exploración de los datos, su preparación, el modelado y la evaluación de resultados.

En este marco, el trabajo se basa en el análisis de datos observacionales, donde la formulación de hipótesis cumple un rol central al guiar el proceso de modelado. El objetivo no se limita a identificar patrones en los datos, sino que busca estimar relaciones entre variables y evaluar su impacto. En particular, se analiza la relación entre la tarifa del servicio y la demanda de pasajeros, integrando herramientas de estadística inferencial con técnicas de aprendizaje automático para su validación empírica.

2.2. Fundamentos de Machine Learning aplicado al transporte urbano

El Machine Learning constituye una rama de la inteligencia artificial que permite desarrollar modelos capaces de aprender patrones a partir de datos sin necesidad de ser programados explícitamente para cada tarea. Dentro de este campo, se distinguen principalmente dos enfoques:

Aprendizaje supervisado, donde el modelo se entrena con datos etiquetados. Se aplica principalmente a problemas de regresión (predicción de valores continuos, como el número de pasajeros) y clasificación (asignación de categorías, como niveles de demanda).

En este trabajo, el aprendizaje supervisado se utiliza principalmente mediante modelos de regresión, dado que la variable de interés —la demanda de pasajeros— es una variable continua. Si bien la clasificación también forma parte del aprendizaje supervisado, no se implementó un modelo de clasificación porque no existe una etiqueta categórica natural en el problema analizado.

Aprendizaje no supervisado, donde el objetivo es descubrir estructuras ocultas en los datos sin etiquetas previas. Técnicas como el clustering permiten identificar agrupamientos naturales entre observaciones.

En el presente trabajo, el aprendizaje no supervisado se aplica mediante K-Means, con el objetivo de identificar grupos de estaciones con perfiles horarios de utilización similares. Este enfoque no busca predecir directamente la cantidad de pasajeros, sino complementar el análisis mediante la segmentación de patrones de comportamiento dentro de la red.

Modelos utilizados

Regresión lineal múltiple: técnica de aprendizaje supervisado que modela la relación entre una variable dependiente continua y múltiples variables independientes, asumiendo una relación lineal. Su ventaja principal radica en la interpretabilidad de los coeficientes, que representan el efecto marginal de cada variable predictora sobre la variable respuesta. La ecuación general toma la forma $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon$, donde β_i son los coeficientes estimados y ϵ es el término de error.

En el caso de este trabajo, la regresión lineal múltiple se aplica mediante una especificación log-log, donde tanto la demanda de pasajeros como la tarifa real se expresan en logaritmos. Esta transformación permite interpretar el coeficiente asociado al precio como una elasticidad-precio de la demanda, es decir, como el cambio porcentual esperado en la cantidad de pasajeros ante una variación porcentual en la tarifa real.

Además, el modelo incorpora variables temporales, efectos fijos por línea y efectos mensuales, con el objetivo de controlar diferencias estructurales entre líneas, estacionalidades y tendencias generales de la demanda. Esta decisión metodológica resulta relevante porque la tarifa del subte es común a todas las líneas, por lo que las diferencias entre ellas deben interpretarse como asociaciones y no como efectos causales completamente aislados.

SARIMA (Seasonal Autoregressive Integrated Moving Average): modelos de series temporales que capturan la estructura de autocorrelación y estacionalidad en datos secuenciales. ARIMA se parametriza mediante tres componentes (p, d, q): el orden autorregresivo, el grado de diferenciación y el orden de media móvil. SARIMA extiende este enfoque incorporando componentes estacionales (P, D, Q, s), lo que resulta especialmente útil para datos con patrones periódicos recurrentes.

En este trabajo se utiliza **SARIMAX**, una extensión de los modelos SARIMA que permite incorporar variables exógenas, como la tarifa. Este enfoque resulta adecuado para analizar la demanda mensual de pasajeros, ya que dicha serie presenta tendencias, estacionalidad y posibles cambios estructurales. Además, permite evaluar la capacidad predictiva del modelo considerando simultáneamente la dinámica temporal de la demanda y el efecto de variables externas.

K-Means: técnica de aprendizaje no supervisado utilizada para agrupar observaciones en función de su similitud. En este trabajo se emplea para segmentar estaciones según la forma de sus perfiles horarios de demanda. El objetivo del clustering no es predecir la cantidad de pasajeros, sino identificar patrones de utilización diferenciados, por ejemplo estaciones con mayor concentración de viajes en horarios laborales o estaciones con flujos más distribuidos a lo largo del día.

Test de Chow: prueba estadística utilizada para evaluar la existencia de un quiebre estructural en una serie o modelo. Permite comparar si una misma relación estadística se mantiene estable a lo largo del tiempo o si, a partir de un determinado punto, el comportamiento de los datos cambia significativamente. En este trabajo se utiliza para analizar posibles rupturas en la evolución de la demanda, especialmente frente a eventos extraordinarios como la pandemia de COVID-19 o cambios relevantes en el contexto tarifario.

Métricas de evaluación

R² ajustado (coeficiente de determinación ajustado): mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo, penalizando la inclusión de variables que no aportan poder explicativo. Un valor cercano a 1 indica un ajuste elevado, mientras que valores bajos sugieren que el modelo no captura adecuadamente la relación entre las variables.

MAE (Mean Absolute Error – Error Absoluto Medio): calcula el promedio de las diferencias absolutas entre los valores predichos y los observados. Ofrece una medida directa e interpretable del error promedio del modelo en las mismas unidades que la variable objetivo.

RMSE (Root Mean Squared Error – Raíz del Error Cuadrático Medio): similar al MAE, pero penaliza con mayor intensidad los errores grandes al elevar al cuadrado las diferencias antes de promediarlas. Resulta útil para detectar modelos con predicciones atípicas significativas.

AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion): criterios de información utilizados en modelos estadísticos y de series temporales para comparar especificaciones alternativas. Ambos buscan equilibrar el ajuste del modelo con su complejidad, penalizando la incorporación excesiva de parámetros. En el caso de SARIMA/SARIMAX, estos criterios permiten seleccionar combinaciones adecuadas de parámetros autorregresivos, de diferenciación, de media móvil y estacionales.

Silhouette score: métrica utilizada para evaluar la calidad de un agrupamiento en técnicas de clustering. Este indicador mide qué tan similares son las observaciones dentro de un mismo grupo en comparación con las observaciones de otros grupos. Valores más altos indican clusters mejor separados, mientras que valores bajos o moderados sugieren agrupamientos menos definidos. En este trabajo se utiliza para evaluar la segmentación de estaciones realizada mediante K-Means.

Parámetros relevantes

En los modelos de regresión, los coeficientes de elasticidad con intervalos de confianza al 95% permiten cuantificar la sensibilidad de la variable dependiente ante cambios en las variables predictoras, con un nivel de certeza estadísticamente significativo. En el modelo SARIMA, la selección de los parámetros (p , d , q) y sus componentes estacionales se realiza mediante criterios de información como AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion), que buscan el equilibrio entre ajuste y parsimonia del modelo.

En los modelos SARIMAX, la selección de los parámetros (p , d , q) y sus componentes estacionales (P , D , Q , s) se realiza mediante criterios de información como AIC y BIC, que buscan el equilibrio entre ajuste y parsimonia del modelo. Asimismo, la incorporación de variables exógenas permite evaluar el efecto de factores externos sobre la serie temporal, como la tarifa real del subte.

En el análisis de clustering, la cantidad de grupos se define a partir de criterios de validación como el silhouette score, procurando identificar una estructura de agrupamiento que sea interpretable y coherente con los patrones horarios observados en las estaciones.

2.3 Elasticidad de la demanda en transporte

Desde la teoría económica, la elasticidad-precio de la demanda mide la sensibilidad de la cantidad demandada ante cambios en el precio. Se define formalmente como el cociente entre la variación porcentual de la cantidad demandada y la variación porcentual del precio. Cuando el valor absoluto de la elasticidad es menor a 1, la demanda se considera inelástica; cuando es mayor a 1, elástica.

En sistemas de transporte público, esta relación suele ser inelástica en el corto plazo, dado que los usuarios dependen del servicio para sus desplazamientos cotidianos y las alternativas de movilidad no son inmediatamente sustituibles. Sin embargo, la elasticidad puede variar según factores como la disponibilidad de modos de transporte alternativos, el nivel de ingresos de la población, las características del servicio (frecuencia, cobertura, comodidad) y el horizonte temporal del análisis.

La literatura sobre economía del transporte señala que, en el largo plazo, incrementos sostenidos en las tarifas pueden provocar desplazamientos modales —es decir, la migración de los usuarios hacia otros medios de transporte— especialmente cuando la brecha de precios entre modos alternativos se amplía significativamente. Este fenómeno puede analizarse mediante modelos de regresión que estimen el efecto marginal del precio sobre la cantidad de pasajeros, controlando por variables temporales y espaciales.

En este trabajo, la elasticidad-precio se estima utilizando la tarifa real, es decir, ajustada por inflación. Esta decisión resulta central en el contexto argentino, ya que el uso de tarifas nominales podría

generar asociaciones espurias debido al aumento generalizado de precios. Al trabajar con precios reales y controles temporales, el análisis busca aproximarse de manera más adecuada a la relación económica entre el costo del viaje y la demanda de pasajeros.

3. Metodología

3.1 Diseño metodológico

El presente trabajo adopta un enfoque **cuantitativo, explicativo y predictivo**, orientado al análisis de datos históricos del sistema de subtes de Buenos Aires. El objetivo no solo es describir el comportamiento de la demanda, sino también construir modelos capaces de estimarla, analizar patrones temporales y evaluar asociaciones entre variables relevantes, como la tarifa real y la cantidad de pasajeros.

El diseño es de tipo **no experimental**, dado que los datos observados no son manipulados, sino analizados en su contexto real.

Aplicación del marco teórico al problema de estudio

Los fundamentos descritos en el marco teórico se aplican de manera directa al análisis de la red de subtes de Buenos Aires. La metodología de investigación en Ciencia de Datos (sección 2.1) estructura el proceso completo de trabajo: desde la formulación de la hipótesis sobre la relación entre tarifa real y demanda hasta la validación cuantitativa mediante modelos predictivos. Los fundamentos de Machine Learning (sección 2.2) proveen las herramientas técnicas para construir los modelos utilizados en el proyecto. En particular, se emplean modelos de regresión lineal múltiple para estimar la elasticidad-precio de la demanda, modelos SARIMA/SARIMAX para analizar la evolución temporal de los pasajeros incorporando la tarifa como variable exógena, técnicas de clustering K-Means para identificar perfiles de utilización de estaciones, y un Test de Chow para evaluar posibles quiebres estructurales en la serie de demanda. Finalmente, el concepto de elasticidad-precio de la demanda (sección 2.3) constituye el eje analítico central de la hipótesis:

El trabajo busca analizar la relación histórica entre tarifa real y demanda utilizando los datos disponibles, y evaluar si la elasticidad observada resulta consistente con los antecedentes académicos sobre transporte público urbano.

A partir de la evidencia disponible, el subte de Buenos Aires transportó en abril de 2025 un 39% menos de pasajeros que en abril de 2019 [1], con una caída acumulada del 44,1% en el primer trimestre de 2025 respecto al período pre-pandemia [4]. El economista Skiadaressis descompone

esta caída en dos componentes: un 20% atribuible a cambios estructurales post-pandemia y otro 20% vinculado a la suba tarifaria [1]. Desde mayo de 2024, el costo del subte duplica al del colectivo —\$963 frente a \$472 en junio de 2025—, acumulando un aumento nominal del 670% entre abril de 2024 y mayo de 2025 [4]. El CEM califica esta situación como una "política tarifaria expulsiva" [5].

Si bien estos antecedentes constituyeron la principal motivación del estudio, el conjunto de datos disponible no permitió analizar directamente la totalidad de los incrementos tarifarios ocurridos a partir de 2024. Por este motivo, el análisis empírico se concentró en los períodos para los cuales se disponía de información histórica consistente, utilizando dichos resultados para contextualizar y complementar la discusión sobre las tendencias más recientes.

La tesis de la UTDT (2020) estimó una elasticidad-precio inelástica (entre -0,1 y -0,2), con diferencias significativas por línea: la Línea D es la más sensible al precio y las Líneas A y E las menos elásticas. Informes del CEM [3] confirman que las líneas B y D registran la mayor pérdida de pasajeros en el período reciente. A nivel internacional, ciudades como Helsinki y Madrid lograron recuperar o superar sus niveles pre-pandemia mediante políticas tarifarias favorables [5], lo que refuerza la relevancia del factor precio como determinante de la demanda.

3.2. Herramientas

Para el desarrollo del presente proyecto se utilizará un conjunto de herramientas de software de código abierto, ampliamente adoptadas en la comunidad de Ciencia de Datos:

- Python: lenguaje de programación principal del proyecto, seleccionado por su amplio ecosistema de librerías orientadas al análisis de datos, el aprendizaje automático y la visualización.
- Pandas: librería para la manipulación y el análisis de datos tabulares. Se utilizará para la carga, limpieza, transformación y exploración del dataset de pasajeros, tarifas y estaciones.
- NumPy: librería de cómputo numérico que provee estructuras de datos eficientes (arrays) y funciones matemáticas utilizadas como base por las demás herramientas del ecosistema.
- Matplotlib y Seaborn: librerías de visualización de datos. Matplotlib ofrece un control granular sobre los gráficos, mientras que Seaborn facilita la creación de visualizaciones estadísticas con una sintaxis más concisa. Se emplearán para el análisis exploratorio (EDA) y la presentación de resultados.

- Scikit-learn: librería de aprendizaje automático que provee implementaciones de modelos de regresión, clasificación y clustering, así como herramientas para la evaluación de modelos (métricas como MAE, RMSE, R^2), la validación cruzada y el preprocesamiento de datos.
- Statsmodels: librería orientada a la modelización estadística y econométrica. Se utilizará para la construcción de modelos de series temporales (SARIMA/SARIMAX), la regresión lineal con análisis de significancia estadística y los tests de cambio estructural.
- Jupyter Notebook: entorno de desarrollo interactivo que permite combinar código, visualizaciones y texto narrativo en un mismo documento. Facilita la documentación reproducible del proceso de análisis y modelado.

3.3. Detalle de las etapas

3.3.1 Etapa 1 – Exploración visual de los datos (EDA)

En esta etapa se realizará un análisis descriptivo inicial del dataset, con el objetivo de comprender su estructura y detectar patrones relevantes y reconocer posibles problemas de calidad en los datos. Se utilizarán técnicas de visualización y estadística descriptiva para:

- Analizar la evolución temporal del flujo de pasajeros.
- Identificar estacionalidades (diarias, semanales, mensuales).
- Explorar diferencias entre líneas y estaciones.
- Evaluar correlaciones entre variables (por ejemplo, tarifa vs pasajeros).
- Este análisis permitirá generar primeras intuiciones sobre la hipótesis planteada.
- Se utilizarán visualizaciones para identificar tendencias generales, caídas abruptas de demanda y posibles puntos de quiebre, especialmente en torno a eventos extraordinarios como la pandemia de COVID-19.

3.3.2 Etapa 2 – Limpieza y transformación

Se procederá a preparar los datos para su uso en modelos de Machine Learning, mediante:

- Tratamiento de valores faltantes (imputación o eliminación).
- Detección y manejo de outliers.
- Detección y manejo de duplicados.
- Transformación de variables (por ejemplo, fechas a variables temporales como día de semana).
- Normalización o estandarización de variables numéricas.
- Se construirán variables derivadas a partir de las fechas, tales como año, mes y otros indicadores temporales necesarios para analizar estacionalidad y tendencias.

- Se construirá la tarifa real, ajustada mediante el Índice de Precios al Consumidor de la Ciudad de Buenos Aires (IPCBA). Esta decisión permitirá evitar relaciones espurias asociadas a la inflación y analizar de manera más adecuada el vínculo económico entre el precio del boleto y la demanda de pasajeros.
- Se agregaran y organizaran los datos en distintos niveles de análisis según el modelo utilizado. Para la regresión lineal múltiple se trabajará con un panel mensual por línea, mientras que para el análisis temporal se utilizarán series agregadas de pasajeros y tarifa. Para el clustering, se construirán perfiles de utilización de estaciones a partir de patrones horarios de demanda.

3.3.3 Etapa 3 – Modelado con Machine Learning

Se implementará el siguiente enfoque de modelado, conectando las técnicas descritas en el marco teórico (sección 2.2) con el problema de estudio:

- **Regresión lineal múltiple:** se aplicará para analizar la relación entre la tarifa real y la cantidad de pasajeros. La especificación utilizada será de tipo log-log, lo que permitirá interpretar el coeficiente asociado a la tarifa como elasticidad-precio de la demanda.
- **SARIMA:** se aplicarán modelos de series temporales con la tarifa como variable exógena para capturar los patrones estacionales de la demanda y proyectar su evolución.
- **SARIMAX:** se aplicará como modelo de series temporales para capturar tendencias, estacionalidades y dependencias temporales en la evolución de la demanda. La tarifa será incorporada como variable exógena, permitiendo evaluar su asociación con la cantidad de pasajeros dentro de una estructura temporal.
- **K-Means:** se utilizará como técnica de clustering para identificar grupos de estaciones con patrones horarios de utilización similares. Aunque no tiene un objetivo predictivo directo, permitirá complementar el análisis mediante la detección de comportamientos diferenciados dentro de la red.
- **Test de Chow:** se aplicará para detectar posibles quiebres estructurales en la serie temporal de pasajeros. Su objetivo será evaluar si existían cambios significativos en el comportamiento histórico de la demanda, especialmente frente a eventos extraordinarios como la pandemia de COVID-19.
- Los modelos serán evaluados utilizando métricas adecuadas según la naturaleza de cada enfoque. En el caso de la regresión lineal se analizarán indicadores como el R^2 ajustado, la significancia estadística de los coeficientes y los intervalos de confianza de la elasticidad

estimada. Para los modelos de series temporales se considerarán criterios de información (AIC y BIC), así como métricas de error y validación sobre períodos de prueba.

3.4. Validación de la hipótesis

Finalmente, se analizarán los resultados obtenidos para evaluar la hipótesis planteada:

- En primer lugar, se estimará el impacto de la tarifa real sobre la demanda mediante modelos de regresión lineal múltiple. Los coeficientes obtenidos permitirán calcular la elasticidad-precio de la demanda y evaluar su significancia estadística.
- En segundo lugar, se analizarán diferencias entre líneas a través de efectos fijos e interacciones, con el objetivo de identificar posibles comportamientos diferenciales frente a las variaciones tarifarias. Dado que la tarifa del subte es común a todas las líneas en un mismo período, estos resultados deberán interpretarse con cautela, como diferencias asociadas a patrones estructurales de cada línea y no como efectos causales completamente aislados del precio.
- En tercer lugar, se aplicarán modelos SARIMAX para incorporar la dimensión temporal del problema y evaluar la capacidad predictiva del enfoque de series temporales. Este análisis permitirá considerar tendencias, estacionalidades y la tarifa como variable exógena.
- En cuarto lugar, se aplicará un análisis de clustering mediante K-Means para complementar la interpretación de la demanda, identificando grupos de estaciones con perfiles horarios similares.
- Finalmente, se utilizará el Test de Chow para detectar posibles puntos de quiebre significativos en la evolución de la demanda. Este análisis permitirá evaluar cambios estructurales en los patrones históricos de movilidad, particularmente asociados a eventos extraordinarios como la pandemia.

Debido a las limitaciones temporales del conjunto de datos disponible, la validación de la hipótesis se realizará sobre los períodos efectivamente observados y no sobre los incrementos tarifarios más recientes. En consecuencia, los resultados deben interpretarse como evidencia empírica sobre la relación histórica entre tarifa real y demanda, más que como una evaluación directa de las políticas tarifarias implementadas a partir de 2024.

4. Propuesta de solución

4.1. Desarrollo del modelo predictivo

El objetivo principal del proyecto consistió en analizar el comportamiento de la demanda de pasajeros de la red de subtes de Buenos Aires y evaluar en qué medida las variaciones tarifarias pueden influir sobre dicha demanda. Para ello se implementaron distintos modelos complementarios, seleccionados en función de las características del problema y de la información disponible.

Como modelo principal se utilizó una **Regresión Lineal Múltiple** sobre un panel mensual conformado por las distintas líneas de subte durante el período 2014-2019. Este enfoque fue elegido porque permite cuantificar de manera directa la relación entre el precio del boleto y la cantidad de pasajeros transportados, estimando la elasticidad-precio de la demanda. La especificación adoptada fue de tipo log-log, lo que posibilita interpretar los coeficientes como variaciones porcentuales y facilita la comparación con estudios económicos previos sobre transporte urbano.

Una decisión metodológica fundamental fue utilizar la tarifa en **términos reales**, ajustada mediante el Índice de Precios al Consumidor de la Ciudad de Buenos Aires (IPCBA). Durante el período analizado, la economía argentina experimentó elevados niveles de inflación, por lo que trabajar con precios nominales podía generar relaciones espurias entre tarifa y demanda. La utilización de precios reales permitió aislar de manera más adecuada el efecto económico del costo del viaje sobre el comportamiento de los usuarios.

Además del precio, el modelo incorporó una tendencia temporal, efectos fijos por línea y efectos fijos mensuales. Estas variables de control permitieron capturar diferencias estructurales entre líneas, patrones estacionales de utilización y cambios de largo plazo asociados a la evolución de la red, evitando atribuir al precio fenómenos que responden a otras causas.

El modelo global estimó una elasticidad-precio de -0,219, con un intervalo de confianza al 95% entre -0,325 y -0,113, y un p-value de 5,955e-05. Esto indica que la relación entre tarifa real y demanda resultó negativa y estadísticamente significativa. En términos interpretativos, un aumento del 10% en la tarifa real se asocia, en promedio, con una disminución aproximada del 2,19% en la cantidad de pasajeros. El R^2 ajustado del modelo fue de 0,894, lo que evidencia una elevada capacidad explicativa de las variables incorporadas.




Figura 1. Gráfico de elasticidad según modelo de regresión lineal múltiple.

Cada barra es la elasticidad estimada de una línea y la barra de error es su IC95%. Todas son **negativas** (signo correcto: a mayor precio, menos viajes). La Línea H (-0,66) es la de mayor magnitud, pero es un **artefacto de la expansión de estaciones** en el período, no sensibilidad al precio, así que no se interpreta. Entre el resto, la **D es la más sensible (-0,16)** y la **E la menos (-0,07)** — el mismo orden que plantea H5. Sin embargo, **todos los IC cruzan el cero y se solapan entre sí**: las líneas no son estadísticamente distinguibles. Esto es esperable porque la tarifa es única para todas las líneas, lo que limita la identificación. Conclusión: el orden **coincide con H5 pero no es concluyente**.

También se estimaron elasticidades diferenciadas por línea. Todas las líneas presentaron coeficientes negativos, lo cual coincide con el signo esperado de una curva de demanda. Los resultados fueron: Línea H (-0,655), Línea D (-0,161), Línea B (-0,148), Línea C (-0,142), Línea A (-0,137) y Línea E (-0,071). Sin embargo, estos resultados deben interpretarse con cautela, ya que los intervalos de confianza de la mayoría de las líneas se solapan y cruzan el cero, por lo que las diferencias no resultan estadísticamente concluyentes.

Un caso particular es el de la Línea H. Durante el período analizado, esta línea experimentó una importante expansión de infraestructura mediante la incorporación de nuevas estaciones. Como resultado, parte del crecimiento observado en la demanda puede explicarse por una mejora en la cobertura y accesibilidad de la red, independientemente de la evolución tarifaria. Por esta razón, el coeficiente asociado a dicha línea no debe interpretarse como una sensibilidad pura al precio.

Como complemento se implementaron modelos de series temporales. En primer lugar, se utilizó un modelo SARIMA puro validado en un régimen estable pre-COVID, entrenado con datos de 2014-2018

y validado sobre 2019. Este modelo obtuvo un AIC de 3059,5, un BIC de 3067,0, un MAE de 1.465.103, un RMSE de 1.777.549 y un R^2 fuera de muestra de 0,465. Estos resultados muestran que, en un contexto estable y sin shocks extraordinarios, el modelo logra capturar razonablemente la dinámica estacional normal de la demanda.

En segundo lugar, se implementó un modelo SARIMAX sobre la serie completa, incorporando la tarifa como variable exógena y una dummy de intervención asociada al COVID-19. La especificación seleccionada fue SARIMAX(0,1,1)x(0,1,1,12). Este modelo obtuvo un AIC de 3388,6 y un BIC de 3401,8. El coeficiente de la tarifa fue negativo (-4.091), mientras que la dummy COVID presentó un efecto de cambio de nivel muy marcado (-21.588.002 pasajeros), lo que refleja la magnitud del shock pandémico sobre la demanda.

En la validación fuera de muestra de los últimos 12 meses, el modelo SARIMAX obtuvo un MAE de 2.399.867, un RMSE de 2.777.837 y un R^2 de -0,451. Si bien este desempeño predictivo no fue elevado, el modelo permitió evitar pronósticos no plausibles, ya que la dummy COVID impidió extrapolar el colapso de la pandemia como si fuera una tendencia permanente. Por lo tanto, su aporte principal no fue lograr una predicción fina de corto plazo, sino representar mejor la estructura temporal de la serie y controlar explícitamente el cambio de nivel producido por la pandemia.




Figura 2. Gráfico de pronóstico de viajes mensuales con modelo SARIMAX.

En azul, los viajes observados; en rojo punteado, el pronóstico del Modelo B sobre los últimos 12 meses (validación), con su banda de confianza. La línea naranja marca el inicio del COVID (la variable de intervención). Dos cosas: (1) gracias a la dummy COVID, el pronóstico se mantiene en **valores plausibles y sigue la estacionalidad** —ya no se va a viajes negativos como sin ella—; (2) el **Modelo A**, validado en el régimen estable de 2019, ajusta bien (R^2 fuera de muestra $\approx 0,47$), lo que confirma que el modelo capta la dinámica normal. El **Modelo B** sobre toda la serie acierta el nivel pero con error mayor (2025 es volátil mes a mes); su valor no es el pronóstico fino sino el **coeficiente de la tarifa controlando por estacionalidad y por el shock COVID**, que resulta chico —

coherente con la baja sensibilidad al precio (\$7.1).

Por otra parte, se aplicó un algoritmo de clustering K-Means con el objetivo de identificar grupos de estaciones con comportamientos horarios similares. Aunque este método no tiene un propósito predictivo directo, permitió descubrir patrones de movilidad dentro de la red y segmentar estaciones según sus características de uso. Esta información resulta útil para complementar el análisis y comprender mejor las dinámicas operativas del sistema.

Para el clustering se seleccionó $k=2$ como cantidad óptima de grupos, de acuerdo con el silhouette score. El valor obtenido fue aproximadamente 0,332, lo cual indica una estructura de agrupamiento moderada. Los clusters agruparon 51 y 36 estaciones respectivamente. Este resultado permite distinguir perfiles horarios diferenciados, aunque debe interpretarse como un análisis exploratorio, dado que la separación entre grupos no es completamente nítida.




Figura 3. Gráfico de elasticidad según modelo de regresión lineal múltiple.

El algoritmo agrupó las estaciones por la **forma** de su curva horaria (sin etiquetas previas) y encontró **2 perfiles**: el **Cluster 0 (n=51)** tiene un **pico marcado a la mañana** (~8 h) — estaciones de tipo residencial, desde donde la gente sale temprano a trabajar; el **Cluster 1 (n=36)** está **más cargado a la tarde** (17-18 h) — estaciones de destino/oficina, donde la gente llega a la mañana y se va al final del día. El silhouette de 0,33 indica una estructura **moderada** (los grupos existen pero no son nítidos) y la muestra no es aleatoria, así que es **ilustrativo**. Aporta a H5 porque muestra que el sistema tiene **patrones de uso de tipo commuting**, justamente los que el teletrabajo erosiona —consistente con el achatamiento del pico matutino que se vio en §4.7—.

Finalmente, se utilizó un Test de Chow para detectar posibles quiebres estructurales en la serie temporal. En particular, el notebook evaluó el quiebre asociado al tarifazo de mayo de 2024. El resultado fue un estadístico F de 1,313 y un p-value de 0,2723, por lo que no se encontró evidencia estadística suficiente para afirmar que dicho evento haya producido un quiebre estructural en la serie de demanda.

Este resultado es relevante porque permite matizar la hipótesis inicial. Si bien la tarifa real presenta una relación negativa y significativa con la demanda en el modelo de regresión, el aumento tarifario de mayo de 2024 no aparece como un punto de ruptura estructural de la serie. En cambio, el análisis temporal muestra que el cambio más fuerte en la dinámica de pasajeros está asociado a la pandemia de COVID-19 y a la posterior estabilización de la demanda en un nivel inferior al observado antes de 2020.

Es importante destacar que la tarifa constituye una variable común para todas las líneas del sistema. Esto implica que no existe variación de precio entre líneas en un mismo período, lo que limita la identificación de efectos diferenciales puramente atribuibles a la tarifa. En consecuencia, los coeficientes estimados representan asociaciones observadas en los datos y no necesariamente relaciones causales completamente aisladas.

4.2 Análisis comparativo de algoritmos utilizados

Los modelos implementados abordaron el problema desde perspectivas diferentes y complementarias.

La Regresión Lineal Múltiple fue el modelo más adecuado para estudiar la relación entre tarifa real y demanda debido a su capacidad interpretativa. A diferencia de otros enfoques más complejos, permite estimar directamente la elasticidad-precio y evaluar la significancia estadística de las variables explicativas. El modelo alcanzó un elevado poder explicativo, evidenciado por un R^2 ajustado de 0,894 en la estimación global y de 0,897 en el modelo con elasticidades por línea. Además, la elasticidad global estimada fue negativa, inelástica y estadísticamente significativa, lo que la convierte en la herramienta central para contrastar la hipótesis vinculada al precio del boleto.

El modelo SARIMA aplicado sobre el período estable pre-COVID aportó una perspectiva temporal útil, ya que logró capturar la estacionalidad normal de la demanda con un R^2 fuera de muestra de 0,465. Esto indica que, en ausencia de shocks estructurales, los modelos de series temporales pueden ofrecer una capacidad predictiva razonable para anticipar la evolución mensual de pasajeros.

El modelo SARIMAX, por su parte, permitió incorporar simultáneamente la dinámica temporal, la tarifa como variable exógena y una dummy de intervención para representar el shock de COVID-19. Aunque su desempeño predictivo fuera de muestra fue limitado, con un R^2 de -0,451, su utilidad radicó en mostrar que la pandemia produjo un cambio de nivel mucho más fuerte que el efecto asociado a la tarifa. Esta evidencia permite comprender por qué un modelo temporal sin intervención puede fallar frente a cambios estructurales abruptos.

Sin embargo, los resultados también evidenciaron una limitación característica de los modelos temporales: su sensibilidad frente a cambios estructurales abruptos. La irrupción de la pandemia de COVID-19 produjo una modificación significativa de los patrones de movilidad urbana, reduciendo la capacidad de los modelos entrenados sobre información previa para anticipar correctamente el comportamiento posterior de la serie.

Por su parte, el algoritmo K-Means cumplió una función exploratoria y descriptiva. Su objetivo no fue predecir la cantidad de pasajeros, sino identificar agrupamientos de estaciones con perfiles de utilización similares. El silhouette score aproximado de 0,332 indica que la estructura de clusters existe, pero no es extremadamente marcada. Por lo tanto, sus resultados deben interpretarse como una herramienta de segmentación complementaria y no como una prueba concluyente sobre la demanda.

El Test de Chow aportó una evaluación específica sobre la existencia de quiebres estructurales. Aplicado al quiebre de mayo de 2024, no encontró evidencia estadística suficiente para afirmar que el tarifazo haya partido la serie de demanda. Este resultado permite diferenciar entre una relación negativa general entre tarifa real y pasajeros, detectada por la regresión, y la inexistencia de un quiebre abrupto atribuible al aumento tarifario de 2024.

En conjunto, los modelos utilizados permitieron abordar el problema desde cuatro dimensiones complementarias: explicación económica de la demanda mediante Regresión Lineal Múltiple, predicción temporal mediante SARIMA/SARIMAX, segmentación de comportamientos mediante K-Means y evaluación de quiebres estructurales mediante el Test de Chow. La combinación de estas metodologías proporcionó una visión más completa del funcionamiento del sistema que la que hubiera podido obtenerse mediante un único enfoque.

4.3 Recomendaciones basadas en los resultados

Los resultados obtenidos permiten formular diversas recomendaciones orientadas a la planificación y gestión del sistema de subtes.

En primer lugar, la elasticidad-precio estimada indica que la demanda responde negativamente a los aumentos de la tarifa real, aunque de forma relativamente moderada. El valor de -0,219 confirma un comportamiento inelástico: los pasajeros reducen su uso ante aumentos del precio, pero en una proporción menor al incremento tarifario. Esto sugiere que el subte continúa siendo un medio de transporte esencial para una parte importante de los usuarios. Sin embargo, aumentos sostenidos pueden contribuir gradualmente a una reducción de la demanda, especialmente en contextos económicos desfavorables.

En segundo lugar, los resultados muestran que existen diferencias entre líneas, aunque no todas son estadísticamente concluyentes. Por este motivo, las decisiones de planificación e inversión deberían considerar las particularidades de cada corredor, pero evitando atribuir automáticamente esas diferencias solo al precio del boleto. En especial, deben contemplarse factores como cobertura territorial, conexión con otros medios de transporte, cambios de infraestructura y patrones de movilidad de los usuarios.

En tercer lugar, la ausencia de evidencia de quiebre estructural en mayo de 2024 sugiere que el aumento tarifario reciente no produjo, por sí solo, una ruptura abrupta en la serie de demanda. Esto no significa que la tarifa no influya sobre los pasajeros, sino que su efecto parece ser gradual e inelástico, más que un cambio repentino de comportamiento.

Asimismo, el impacto de la pandemia de COVID-19 evidencia la necesidad de actualizar periódicamente los modelos predictivos. Los cambios en los hábitos de movilidad pueden modificar sustancialmente las relaciones observadas en períodos anteriores, reduciendo la capacidad predictiva de modelos contruidos exclusivamente sobre información histórica.

Los resultados del clustering sugieren además la conveniencia de diseñar estrategias operativas diferenciadas según los perfiles horarios de utilización de las estaciones. La identificación de grupos con características similares podría contribuir a optimizar la asignación de recursos, frecuencias y capacidades de servicio, especialmente en estaciones con picos concentrados o con una demanda más distribuida a lo largo del día.

Finalmente, se recomienda ampliar las bases de datos utilizadas incorporando de manera sistemática información actualizada posterior a 2021 y consolidando la extensión 2022-2025, así como variables relacionadas con frecuencia del servicio, interrupciones operativas, calidad percibida, indicadores socioeconómicos y medios alternativos de transporte. Esto permitiría construir modelos más robustos, mejorar la identificación de efectos causales y evaluar con mayor precisión el impacto de los incrementos tarifarios recientes sobre la demanda.

5. Conclusiones

5.1. Contraste entre hipótesis y resultados obtenidos

El objetivo principal consistió en analizar la evolución de la demanda de pasajeros de la red de subtes de Buenos Aires y estudiar la influencia de las variaciones tarifarias sobre dicha demanda mediante técnicas de Ciencia de Datos y modelado estadístico.

La hipótesis central planteó que los aumentos sostenidos en la tarifa real del subte podrían asociarse con una disminución en la cantidad de pasajeros transportados. A partir de los resultados obtenidos, esta hipótesis puede considerarse parcialmente validada, aunque con matices importantes. Se confirma la existencia de una relación negativa e inelástica entre tarifa real y demanda, pero no se encuentra evidencia suficiente para afirmar que el aumento tarifario reciente haya producido un quiebre estructural abrupto en la serie de pasajeros.

A través del modelo de Regresión Lineal Múltiple se estimó una elasticidad-precio negativa de la demanda. El coeficiente global obtenido fue de -0,219, con un intervalo de confianza al 95% entre -0,325 y -0,113, y un p-value menor a 0,001. Esto indica que la relación entre tarifa real y demanda resultó estadísticamente significativa. En términos interpretativos, un aumento del 10% en la tarifa real se asocia, en promedio, con una disminución aproximada del 2,19% en la cantidad de pasajeros.

La magnitud de dicha elasticidad evidencia un comportamiento inelástico. Esto implica que, si bien los usuarios reaccionan frente a los aumentos tarifarios, la reducción en la demanda es proporcionalmente menor que el incremento observado en el precio. Este resultado es consistente con la naturaleza del servicio analizado, ya que el subte constituye un medio de transporte fundamental para una gran cantidad de usuarios urbanos, cuyo uso no depende exclusivamente del costo del boleto sino también de factores como la ubicación de las estaciones, los tiempos de viaje, la conectividad con otros medios de transporte y la disponibilidad de alternativas.




Figura 4. Gráfico de serie temporal del total de viajes en subte en CABA.

La serie deja ver tres regímenes claros:

2014-2019 (pre-pandemia): demanda estable con fuerte estacionalidad (caídas en enero y julio por vacaciones), oscilando entre ~17M y ~32M de viajes mensuales, con el pico en 2018-2019.

2020-2021 (COVID, franja roja): derrumbe abrupto en marzo-2020 (de ~30M a ~2M) y recuperación lenta y parcial durante 2021. Es el único quiebre estructural de toda la serie (confirmado por el test de Chow, S7.3).

2022-2025 (post-pandemia): la demanda se recompone y recupera su estacionalidad, pero se estabiliza en torno a 20-25M, por debajo del nivel pre-2020 (~30M). Esa brecha persistente es consistente con un cambio estructural de hábitos (teletrabajo), no con un efecto del precio.

Precio vs. demanda (eje derecho, tarifa nominal). La tarifa se mantiene casi plana hasta 2022 y luego se dispara, con el salto del tarifazo de 2024 hasta ~\$1.000. Pese a ese aumento nominal enorme, la serie de viajes no muestra ninguna caída asociada: mantiene su nivel y su estacionalidad. Es la evidencia visual del resultado central del trabajo —demanda inelástica al precio (S7.1) y sin quiebre en el tarifazo de mayo-2024 (S7.3)—: el factor que hunde la demanda es la pandemia, no la tarifa.

El análisis también permitió identificar que la tarifa no constituye el único factor relevante para explicar la evolución de la demanda. La incorporación de variables temporales, efectos fijos por línea y efectos mensuales mostró que existen diferencias estructurales entre líneas y patrones estacionales que influyen sobre la cantidad de pasajeros transportados. En particular, las elasticidades estimadas por línea fueron negativas, aunque no todas resultaron estadísticamente distinguibles entre sí debido al solapamiento de los intervalos de confianza.




Figura 5. Gráfico de elasticidad según modelo de regresión lineal múltiple.

Con precio **nominal**, viajes y precio correlacionan **+0,71** (positivo): parecería que a mayor precio, mayor demanda. Es **espurio** —ambos suben arrastrados por la inflación y la expansión de la red—. Al pasar a precio **real** (deflactado por IPC), la correlación se invierte a **-0,64** (Spearman -0,43): a mayor precio real, menos viajes, que es lo que se espera de una curva de demanda. Esto justifica trabajar con precio real en todo el modelado y anticipa una elasticidad negativa e inelástica (\$7.1)

En relación con las diferencias por línea, los resultados muestran un orden parcialmente consistente con la hipótesis: entre las líneas tradicionales, la Línea D aparece como una de las más sensibles al precio y la Línea E como una de las menos sensibles. Sin embargo, esta evidencia debe interpretarse con cautela, ya que la tarifa del subte es común a todas las líneas y, por lo tanto, la identificación de elasticidades diferenciales presenta limitaciones. Además, el caso de la Línea H no debe interpretarse como una sensibilidad pura al precio, dado que durante el período analizado experimentó una expansión de infraestructura que pudo haber afectado su demanda.

El Test de Chow no permitió afirmar la existencia de un quiebre estructural significativo asociado al tarifazo de mayo de 2024. El resultado obtenido fue un estadístico F de 1,313 y un p-value de 0,2723, por lo que no se rechazó la hipótesis de ausencia de quiebre estructural. Esto significa que, aunque la tarifa real se asocia negativamente con la demanda, el aumento tarifario de mayo de 2024 no aparece como un punto de ruptura abrupta en la serie de pasajeros.

En cambio, el análisis temporal mostró que el cambio más fuerte en la dinámica de la demanda está asociado a la pandemia de COVID-19. El modelo SARIMAX incorporó una dummy de intervención para representar este shock y estimó un efecto de cambio de nivel muy marcado, equivalente a una caída aproximada de 21,6 millones de pasajeros. Este resultado evidencia que la pandemia produjo

una modificación estructural en los patrones de movilidad, generando un nuevo nivel de demanda inferior al observado antes de 2020.

El modelo SARIMA validado sobre el período estable pre-COVID mostró una capacidad predictiva razonable, con un R^2 fuera de muestra de 0,465. Esto indica que, en contextos sin shocks extraordinarios, los modelos de series temporales pueden capturar la dinámica estacional normal de la demanda. Sin embargo, el modelo SARIMAX aplicado a la serie completa presentó un desempeño predictivo más limitado en los últimos 12 meses, con un R^2 fuera de muestra de -0,451, lo que refleja la dificultad de predecir la demanda en un contexto posterior a cambios estructurales abruptos.

Por su parte, el análisis mediante K-Means permitió identificar dos grupos de estaciones con perfiles horarios diferenciados. El silhouette score aproximado fue de 0,332, lo que indica una estructura de agrupamiento moderada. Este resultado no debe interpretarse como una conclusión predictiva fuerte, sino como una herramienta exploratoria que permite observar diferencias en los patrones de uso de las estaciones, especialmente entre perfiles más asociados a horarios de ingreso laboral y perfiles con mayor carga hacia la tarde.

En conjunto, los resultados permiten concluir que la demanda del subte responde negativamente al precio, pero con baja elasticidad. La tarifa influye sobre la cantidad de pasajeros, aunque no alcanza para explicar por sí sola la caída estructural observada en la serie. La evidencia más fuerte apunta a que la pandemia y los cambios posteriores en los hábitos de movilidad constituyen factores centrales para comprender la disminución de pasajeros, mientras que la tarifa opera como un factor económico relevante pero de efecto gradual e inelástico.

Finalmente, es importante señalar que la disponibilidad y calidad de los datos constituye una limitación relevante para el estudio. Si bien el notebook incorpora una extensión de la serie hasta 2025 para evaluar el período reciente, la regresión principal de elasticidad se estimó sobre el panel mensual 2014-2019, por tratarse del período con información histórica más consistente para ese modelo. Por este motivo, las conclusiones deben interpretarse dentro del alcance metodológico definido y no extrapolarse automáticamente como una explicación completa de todas las dinámicas actuales del sistema.

5.2. Reflexión sobre la validez del modelo predictivo en la toma de decisiones de transporte

Los resultados obtenidos a lo largo del proyecto permiten concluir que las técnicas de Ciencia de Datos y Machine Learning constituyen herramientas valiosas para apoyar la toma de decisiones en sistemas de transporte urbano.

La combinación de modelos econométricos, series temporales y técnicas de segmentación permitió analizar la demanda desde diferentes perspectivas, proporcionando evidencia cuantitativa para comprender el comportamiento de los usuarios y detectar patrones difíciles de identificar mediante métodos descriptivos tradicionales.

Particularmente, la estimación de la elasticidad-precio aporta información relevante para organismos responsables de la planificación tarifaria. Conocer la sensibilidad de la demanda frente a variaciones en el precio permite anticipar posibles efectos sobre la cantidad de pasajeros transportados. En este caso, el valor estimado de $-0,219$ muestra que la demanda responde al precio, aunque de manera inelástica, por lo que los cambios tarifarios deberían evaluarse considerando no solo su impacto recaudatorio, sino también sus efectos graduales sobre el uso del sistema.

No obstante, los resultados también evidencian las limitaciones inherentes a cualquier modelo predictivo. La capacidad de predicción depende directamente de la calidad, cantidad y actualidad de los datos disponibles. Factores externos extraordinarios, como la pandemia de COVID-19, pueden alterar drásticamente los patrones históricos y reducir la capacidad de generalización de modelos construidos sobre información previa. Esto se observó especialmente en los modelos de series temporales, cuyo desempeño varió considerablemente entre el período estable pre-COVID y la serie completa con shocks estructurales.

Asimismo, la demanda de transporte responde a múltiples variables que no pudieron incorporarse en el presente estudio, entre ellas la calidad del servicio, la frecuencia de las formaciones, los niveles de actividad económica, los cambios en los hábitos de movilidad y la disponibilidad de medios alternativos de transporte. La ausencia de estas variables limita la capacidad explicativa de los modelos y constituye una oportunidad de mejora para futuras investigaciones.

En consecuencia, los modelos desarrollados no deben interpretarse como herramientas capaces de predecir con exactitud absoluta el comportamiento futuro de la demanda, sino como instrumentos de apoyo para la toma de decisiones basadas en evidencia. Su principal valor radica en

complementar el conocimiento de los especialistas, identificar patrones generales, cuantificar asociaciones relevantes y aportar información objetiva para la planificación y gestión del sistema.

Desde una perspectiva de política pública, los resultados sugieren que las decisiones tarifarias deberían analizarse junto con otros factores estructurales del sistema. El hecho de que la demanda sea inelástica no implica que los aumentos tarifarios no tengan consecuencias, sino que sus efectos sobre la reducción de pasajeros tienden a ser moderados y graduales. A su vez, la ausencia de un quiebre estructural significativo en mayo de 2024 indica que la caída de pasajeros no puede explicarse únicamente por dicho aumento, sino que debe comprenderse dentro de un proceso más amplio de transformación de la movilidad urbana posterior a la pandemia.

Como línea futura de trabajo, resultaría especialmente relevante incorporar información más completa y actualizada sobre el período 2020-2025, mejorar la reconstrucción mensual de tarifas, incluir variables de calidad del servicio y frecuencia, y sumar indicadores que permitan medir de forma más directa el efecto del teletrabajo y de los cambios en los patrones de movilidad. También sería conveniente reestimar la elasticidad mediante modelos de panel con errores estándar robustos o clusterizados por línea, para mejorar la validez estadística de las comparaciones entre corredores.

En síntesis, el proyecto permitió validar parcialmente la hipótesis planteada: se confirmó una elasticidad-precio negativa, inelástica y estadísticamente significativa; se encontró evidencia compatible con diferencias entre líneas, aunque no concluyente; y se refutó la forma fuerte de la hipótesis que atribuía al tarifazo reciente un quiebre estructural dominante. La principal conclusión es que la demanda del subte está influida por la tarifa, pero también por factores temporales, estructurales y post-pandémicos que deben ser considerados en cualquier análisis serio de planificación del transporte urbano.

Referencias

- [1] Chequeado. (2025). [Aumentó el subte en CABA: ¿qué promociones ofrecen los bancos y billeteras virtuales para pagar menos el boleto?](#)
- [2] Chequeado. (2025). [Cada vez menos gente viaja en el subte porteño: la cantidad de pasajeros cayó un 39% desde 2019.](#)
- [3] Centro de Estudios Metropolitanos. (2025). [Cada vez menos gente viaja en subte.](#)
- [4] Infobae. (2025). [Se desplomó 40% el uso del subte desde la pandemia: el impacto del teletrabajo y la suba del boleto.](#)
- [5] Observatorio del Derecho a la Ciudad. (2025). [Informe sobre la evolución de pasajeros y la tarifa del subte de Buenos Aires \(2015–2025\).](#)

Anexo

Trabajo Práctico completo (informe/Notebook con soluciones):  Metodología de la Investigación

UGR